


1. 단백질 결정화은행의 구축

1. 단백질 결정화은행의 구축 목적

1. 단백질 결정화 및 X-ray 구조해석 데이터를 효율적으로 축적 및 공유
2. 구조기반 신약개발 연구에 최적화된 데이터 플랫폼 제공
3. AI/ML 기반 결정화 예측 모델 및 신약 후보물질 설계에 활용
4. 국내 단백질 구조 연구의 글로벌 경쟁력 확보 및 협업 촉진



5. 단백질 결정화은행의 구축 세부 수행 내용


6. 신약개발 과정에서 표적 단백질의 구조 분석이 필수적인 요소로 작용함에 따라, 외부 수요에 대응하여 표적 단백질-약물 후보물질 복합체의 3차원 구조를 제공하기 위해 주요 질환 표적 단백질의 발현, 정제, 결정화 방법을 사전에 확보하는 것이 필요
7. 제약산업의 요구에 맞춰 표적 단백질의 발현, 정제 및 결정화 데이터를 데이터베이스화하고, 이를 기반으로 표적 단백질-약물 복합체 구조를 신속하게 제공하는 시스템을 구축
8. 결정화 기술이 확립된 표적 단백질을 활용한 기술 서비스를 제공하고, 결정화 데이터베이스를 통해 신약개발을 지원
9. 주요 질환 표적 단백질의 고성능 결정화 기술을 개발하고, 단백질 분석 기술의 통합 운영체계를 구축하여 결정화 과정의 효율성 극대화

10. 국내에는 다양한 노하우를 갖춘 결정화 전문 기관이 부족하며, 이에 따라 필요 시 신속하게 결정화 기법 및 구조 정보를 제공하여, 구조 기반 신약개발(SBDD, Structure-Based Drug Design)을 활성화할 수 있도록 지원
11. 결정화은행(Crystallization Bank)은 흩어져 있는 단백질 구조 연구 및 신약개발을 위한 단백질 결정화 및 구조 분석 데이터를 체계적으로 저장·관리하는 데이터베이스(DB) 시스템으로, 신약개발의 핵심인 구조 기반 약물 설계(SBDD)를 위한 단백질-리간드 상호작용 연구를 효과적으로 지원
12. 단백질 결정화은행의 활용 분야
 13. 신약개발 및 바이오의약 연구: 단백질-리간드 상호작용 분석 및 신약 후보물질 발굴
 14. 단백질 구조 연구: Cryo-EM, X-ray 회절 기반 단백질 구조 규명
 15. AI/ML 기반 예측 모델: 단백질 결정화 성공률 예측 및 신약 타겟 발굴
 16. 생명과학 데이터 공유: 글로벌 연구 커뮤니티 및 산업 협력 지원


구분	세부항목	상세설명
단백질 기본 정보 (Protein General Information)	단백질 ID (Protein ID)	PDB ID, UniProt ID 등 고유 식별자
	단백질명 (Protein Name)	단백질 공식명(예: KRAS, EGFR)
	유래 종 (Organism Source)	인간(Human), 박테리아(Bacteria), 바이러스(Virus) 등
	발현 시스템 (Expression System)	E. coli, HEK293, CHO cells 등
단백질 생산 및 정제 정보 (Protein Production & Purification)	제조할 발현 벡터 정보	사용된 발현 벡터에 대한 정보
	벡터 종류 (Vector Type)	e.g., pET, pcDNA3 등
	태그 종류 (Tag Type)	e.g., His-tag, GST-tag, FLAG-tag
	발현 조건 (Expression Conditions)	발현 온도, IPTG 농도, 발현 시간 등
결정화 데이터 (Crystallization Data)	정제 방법 (Purification Method)	Ni-NTA, SEC, Ion Exchange 등 다양한 정제법 활용
	결정화 스크리닝 정보	사용된 스크리닝 키트 (예: JCSG+, PACT, Index 등)
	pH, 염 농도, 침전제 조성 (pH, Salt Concentration, Precipitant Composition)	pH, 염 농도, 침전제 (PEG, Ammonium Sulfate 등) 조성
	결정화 최적 조건 (Optimized Conditions)	단백질 농도, 첨가제, 결정화 방식 (Hanging drop, Sitting drop 등)
	결정 형태 (Crystal Morphology)	바늘형, 판형, 정육면체 등 결정의 형태 및 크기 정보

17. 신약개발 실험 데이터 체계적 수집 및 통합 데이터 허브 구축
18. 신약개발 연구데이터 수집/관리/활용체계 설계
19. 단백질 구조분석 및 신약개발 연구데이터 유형의 분류

구분	세부내용
실험데이터	단백질/신약 합성·제조 등 실험과정에서 생산되는 연구데이터
분석데이터	측정분석장치에 의하여 생산된 데이터(값, 스펙트럼, 이미지 등)
계산데이터	계산과학 기반 컴퓨터 시뮬레이션에 의해 생산된 데이터
해석데이터	분석/계산데이터 등을 해석하여 물성값 등을 추출한 데이터
문헌데이터	연구자의 연구과정 및 데이터가 정제/종합되어 기록된 문헌(논문, 특허, 보고서)



20. 표적 단백질 발현, 구조분석, 상호작용 및 및 신약개발 연구는 "단백질/화합물", "공정", "측정·분석", "계산과학", "해석"으로 연구과정으로 구성
21. 위 5가지 항목을 조합하여 단백질 구조 및 신약개발 연구자의 연구과정을 도식화 가능



22. 각 연구자/연구그룹이 자신의 연구과정을 연구워크플로우로 도식화하고 이 도식을 기반으로 데이터를 입력할 수 있도록 만들면, 모든 연구자가 자신의 연구데이터를 입력할 수 있는 유연한 시스템으로 구현될 수 있음
23. 이러한 수집체계는 공정/계산/측정법의 변화 등 연구과정이 변화하더라도 연구의 연속성을 유지한 채로 연구데이터를 효율적으로 수집 가능
24. 신약개발 연구데이터 표준화
25. 표준을 반영한 연구워크플로우 템플릿 체계 고도화
 1. “단백질/화합물”, “공정”, “측정·분석”, “계산과학”, “해석”의 연구과정별 항목들은 국가바이오데이터스테이션(K-BDS)를 통하여 이루어지고 있음
 2. 본 연구팀이 개발 및 구현한 “연구워크플로우” 온라인 입력기능은 모든 연구과정을 수집할 수 있는 유연한 수집체계로 현 K-BDS에 제정되어 있지 않은 메타데이터를 포함하여 수집
 3. 따라서, 본 연구팀은 K-BDS에서 제공하고 있는 표준화된 데이터타입, 데이터별 항목 등을 DB화하여, 선행적으로 개발된 입력기능의 “단백질/화합물”, “공정”, “측정분석”, “계산과학”, “해석” 등 항목 검색에 활용될 수 있도록 고도화할 계획
 4. 이렇게 제작된 연구워크플로우는 연구자의 연구과정을 입력할 수 있는 “템플릿” 역할을 수행하며, “템플릿 제작 ⇨ 데이터 입력” 프로세스로 데이터 수집체계를 구성하고자 하며, 수집된 데이터를 K-BDS와 연계하여 자동으로 데이터 등록이 이루어지도록 연동 기술을 개발하여 구축할 계획
5. 계산과학 시뮬레이션 도구의 입/출력 데이터 표준화
6. 분자동역학(Molecular Dynamics) 및 화학구조 양자계산 등 계산과학에 기반한 연구과정은

단백질 구조분석 및 규명에 중요한 역할을 할 뿐만 아니라, 단백질과 신약 화합물 간의 반응성의 이론적 예측과 메커니즘 규명에 핵심적 역할을 수행

7. 따라서, 계산과학 데이터를 수집하고 각 데이터의 해석결과를 추출, 단백질 구조 규명, 단백질과 후보물질의 상호작용 및 신약개발 연구과정에서 적극적 활용할 필요성 존재
8. VASP, Quantum Espresso, WIEN2k, LAMMPS 등 다양한 계산과학 상용패키지 프로그램의 입/출력 데이터 형식은 상이하며 통일되어 있지 않음으로 표준화를 수행함


그림 VASP(좌) 와 QuantumEspresso(우) 입/출력데이터 메타데이터 표준화를 위한

Terminology 조사

9. 신약개발 데이터 허브 기반 인공지능 활용체계 설계 및 개발
10. 온라인 인공지능 모델 개발 기능 개발 및 구축
11. 연구자가 선택한 데이터를 훈련용 데이터셋을 선택하여 Python 등 스크립트 기능이 제공되는 인공지능 모델 개발 화면을 제공
12. 선택 된 데이터셋을 이용하여 통계처리, 데이터분석, 인공지능 모델 개발 등 다양한 제공된 기능들을 통하여 물성을 예측하거나 소재 제조 공정 최적화 등을 수행할 수 있는 인공지능 모델 개발 기능을 플랫폼 상에서 제공
13. 따라서, 온라인상에서의 인공지능 모델 개발 기능은 다음의 기능들을 제공 필요
 - ① 데이터처리 파이프라인(워크플로우) 구성 기능
 - ② Python 등의 스크립트 작성 및 스크립트를 “노드화”한 데이터 파이프라인 구성 기능
 - ③ 간단한 데이터분석 및 통계결과의 시각화 기능(분포도, 상관관계, Pearson plot 등)
 - ④ 인공지능 모델(각종 regression, k-nearest neighbor, XGBoost 등) 개발 기능

⑤ 개발된 인공지능 모델의 테스트셋 예측결과 시각화 기능

14. 또한, 개발한 모델 혹은 타연구자가 개발하여 제공된 인공지능 모델을 실행하여 결과를 확인할 수 있는 기능을 개발하여 플랫폼 내 온라인에서 활용할 수 있도록 제공할 계획
15. 모든 인공지능 개발/활용 기능들은 플랫폼 내 축적된 데이터를 활용하도록 하여, 연구자가 플랫폼에 데이터를 공여하도록 유도



16. 연구데이터 DB구조 설계 및 구축

17. 클라우드 인프라를 고려한 MongoDB 기반 설계

18. 분산시스템 대용량 데이터 처리에 우수한 성능을 보유한 NoSQL DB
19. MongoDB는 NoSQL, Document 지향 데이터베이스로, RPC 프로토콜을 활용하여 시스템 간 상호작용을 지원하고, 이를 통해 고성능, 고가용성, 그리고 쉬운 확장성을 제공
20. 데이터는 BSON(Binary JSON) 형식으로 저장되며, 이진 직렬화로 처리 속도가 향상되고 저장 공간을 더 효율적으로 활용 가능하며, BSON은 텍스트 형식보다 처리 속도가 빠르고 디코딩과 인코딩 과정에서 뛰어난 성능을 제시
21. MogoDB에 저장할 각 Document는 온톨로지 기반 표준화된 어휘를 기준으로 각 어휘가 연구과정에서의 연결관계 정보가 중첩된 구조로 저장
22. 이를 통해 각 연구자의 연구과정에 대한 정보가 체계적으로 기록되고 실험 결과 및 파라미터들도 함께 포함하기 때문에 MongoDB를 사용하여 단백질 구조 및 신약개발 연구데이터를 모델링하면 복잡한 구조의 데이터를 효율적으로 관리 가능

23. 클라우드 인프라 활용 플랫폼 아키텍처 설계

24. 다양한 기관 간 상이한 네트워크/데이터 보안 정책을 고려하여, 공공기관 활용 공인된 클라우드시스템을 활용하여 신약개발 AI 데이터 허브를 구축
25. 플랫폼의 사용자가 필요로 하는 주요 기능과 연구데이터 활용의 기술적 특성 등 제약사항을 고려하여 다수 기능 계층(Layer)을 둔 플랫폼 제안
26. 신약개발 AI 데이터 허브의 기능 계층(Layer)은 다음과 같음

구분	세부내용
소스	정형·비정형 데이터 원천이 존재하는 계층
수집	소스에 위치한 데이터를 배치 또는 실시간으로 데이터를 적재하는 계층
저장	수집한 데이터를 형식 또는 유사도, 소유권 등 기준에 따라 분류·저장하는 계층
분석	저장된 데이터를 1차, 2차, 3차 가공 재가공 또는 테스트하는 계층
서비스	연구자가 원하는 데이터 검색·추천·활용 등 기능이 제공되는 서비스 계층





그림. 신약개발 AI 데이터 허브의 클라우드 아키텍처(안)

27. 산재된 소재 연구 데이터 수집을 위한 통합 레포지터리 구축
28. 각 기관별 산재된 온-프레미스 저장소의 데이터의 등록/연계 -> 검색/조회 -> 분석/활용 등 사용자 중심의 체계적 관리를 위하여 기관별 온-프레미스 저장소와의 연계 기술 개발을 수행
29. 각 기관과의 논의를 통하여 SSO 통합로그인, API 기술 개발 등을 수행하고, 각 실험데이터 및 메타데이터가 연계되어 검색 및 수집될 수 있도록 연계
30. 수요 기관 중 인프라와 기술 개발 지원이 필요한 경우, 별도 스토리지를 제공하고 필요시 기술 지원 인력을 배치하여 데이터 수집 가속화
31. 기관별 레포지터리 제공 및 연구데이터 통합관리를 위한 실질적 활용 기반 마련
32. 연구분야별 레포지터리를 제공하고 이를 신약개발 AI 데이터 허브에서 통합 관리하고 각 기관별 제공 데이터 유형 및 관리체계를 고려하여 레포지터리 구축 시 기관별 요구사항을 반영하여 커스터마이징 제공
33. 데이터 허브 및 AI 분석환경 클라우드 인프라 설계 및 구축
34. 데이터 허브 및 AI 분석환경 S/W 아키텍처
35. 인프라 부분은 공공기관 활용 공인된 클라우드 상에서 컨테이너 기반의 쿠버네티스 환경 제공, PyTorch 등 AI 개발 프레임워크 지원, GPU 자원 관리, Two-factor backup 등으로 구성
36. 데이터 수집 및 품질관리를 통한 공정도 생성, 버전관리 및 통합 관리를 위한 프로토콜 프레임워크를 개발하고 데이터 수집, 관리 및 AI 가이드라인 프레임워크를 설계




37. 신약개발 포털 플랫폼 구축(Drug Development Portal Platform)

38. 세부 수행 내용



39. KBSI 오창연구소 기구축 단백질 구조연구 첨단바이오 대형연구시설 및 전문가들이 신약개발 산업체들이 필요로 하는 장비, 기술을 제공하고 소통, 협업, 심화연구를 할 수 있는 허브로서의 역할을 수행
40. 국내에 이미 구축된 첨단 대형 연구장비의 공유·활용 체계를 구축하여 디지털바이오 R&D 혁신을 위한 기반 구축을 위해 활용
41. 플랫폼 사업에서 얻어진 단백질결정화 기술 및 구조연구 결과를 수렴, 집적화하여 단백질결정화 은행을 운영하여 연구결과를 보전하고 활용



42. 과학적 우수성과 중개 연구 가능성에 대한 신속한 동료 평가를 통해 산업체 신약개발 연구자에게 접근을 허용
43. 단백질 구조기반 신약개발 연구 커뮤니티를 확대하고 강화하기 위한 실무 강좌, 워크숍 등 네트워킹 및 교육 활동을 수행
44. 신약개발 포털에서 제공하는 연구결과의 질과 양을 높이기 위한 공동연구 수행
45. 신약개발 업체의 모든 연구자들이 고급 구조 생물학 시설(NMR, X-ray, Cryo-EM, 단백질 특성 분석장비)을 이용하여 신약개발(예: 약물 발견, 표적 검증) 관련된 중개 연구를 수행
46. 신약개발 포털의 운영체제
 47. (신약개발 포털 시스템 연계를 통한 첨단바이오 대형 연구 장비 활용 신약개발 계획 심의·등록의 통합체계 구축 및 효율화) 신약개발플랫폼 활용계획서 심의위원회 설치 및 운영 및 심의 통과된 신약개발 프로젝트에 대한 첨단바이오 대형 연구 장비의 활용 비용 지원
 48. (첨단 대형 연구 장비 공유·활용을 위한 원스톱 시스템 구축) 프로젝트 컨설팅과 장비 연계 활용 시스템 구축 및 전담 조직 구성(행정 인력, 장비별 운영 인력, 데이터 관리 및 분석 인력으로 구성) 및 전문가로 구성된 프로젝트 컨설팅 위원회 설치 및 운영, 수집된 바이오 데이터의 관리·분석 시스템 구축 등
 49. (현장 실무형 전문인력양성 프로그램 구축 및 운영) 산학연 수요 기반 이용자 및 연구 장비 운영 관리자 교육 프로그램 구축 및 운영

50. 신약개발 데이터 확보 전략

51. 활용 데이터의 종류 및 출처

데이터 유형	내용	출처	확보 방법
단백질 3차원 구조 데이터	실험적으로 규명된 단백질-복합체 구조(X-ray, Cryo-EM, NMR)	공공	PDB(Protein Data Bank) 다운로드
AI 예측 단백질 구조	AlphaFold Structure Database 예측 구조	공공	AlphaFold DB 다운로드
약물-표적 상호작용 데이터	결합력(Kd, IC50), 약효 정보, 화합물 구조	공공	ChEMBL, PubChem, BindingDB 다운로드 및 문헌 수집
단백질 서열 정보	다중서열정렬(MSA), 동종단백질 서열	공공	UniProt, NCBI 다운로드
분자절편(Fragment) 정보	약물 합성용 분자절편 구조, 결합 가능 위치	공공·상용	ZINC20, Enamine REAL database 다운로드
표적단백질 발현·정제·결정화 조건	발현 벡터, 발현 조건, 정제 방법, 결정화 스크리닝 결과	자체 생산	핵심과제 1·3 연구 수행 과정에서 생산·축적
NMR 동적구조 데이터	Relaxation dispersion, CEST, chemical shift 데이터	자체 생산	KBSI 1.2 GHz NMR 등 대형연구 장비 실험
Cryo-EM 구조 다양성 데이터	Conformational landscape, 3D classification 결과	자체 생산	KBSI Cryo-EM 실험
Bio-SAXS 산란 데이터	용액 상 단백질 형태·크기·복합체 형성 데이터	자체 생산	KBSI Bio-SAXS 실험
분자동역학 시뮬레이션 데이터	MD trajectory, 결합 자유에너지, 동적구조 앙상블	자체 생산	충북대·KBSI 계산과학 수행
바이오제약사 약물 MOA 분석 데이터	기업 수요 표적단백질-약물 복합체 구조·상호작용 데이터	민간(NDA)	기업 전담 사무국을 통한 NDA 기반 공동연구

52. KBSI가 보유한 도메인 데이터(NMR relaxation dispersion 기반 동적구조, Cryo-EM conformational landscape, 단백질-약물 복합체 구조)는 AI 모델의 학습·검증 데이터로 직접 활용

53. 본 과제에서 5년간 생산하는 100건 이상의 MOA 분석 및 250종을 비롯하여 체계적으로 수집된 결정화은행 데이터를 AI 고도화의 핵심 자원으로 축적함으로써, 국내에 부재했던 신약개발 실험 빅데이터 기반을 확보

54. 데이터 표준화 및 자산화

55. 개별 연구 종료 시 소멸되는 실험데이터를 표준화·자산화하여, AI 학습 기반과 산업적 데이터 보안을 동시에 확보

56. K-BDS 표준 메타데이터와 연계한 연구워크플로우 기반 수집 체계를 구축하고, MongoDB(BSON) 기반으로 저장·관리함으로써, 개별 연구 종료 시 소멸되는 실험데이터의 체계적 자산화를 실현

57. 기업 데이터는 NDA 기반 권한별 접근 체계를 적용하여 산업적 가치를 보호하되, 표준화된 익명 데이터에 한해 AI 학습에 활용함으로써 데이터 보안과 활용 효율 간의 균형을 확보

